

전처리 단계별 상세 설명

1. 결측치 처리

방법론: SimpleImputer (중앙값 대체)

상세 설명:

- 데이터셋에 존재하는 결측치를 해당 특성의 중앙값으로 대체합니다.
- 중앙값을 사용하는 이유는 이상치에 강건하며 데이터 분포를 잘 보존하기 때문입니다.
- 결측치 처리를 통해 모델 학습 시 발생할 수 있는 오류를 방지하고 데이터 손실을 최소화합니다.

비즈니스 의미:

- 일부 사용자의 데이터가 부족하다라도 중앙값을 통해 안전하게 예측 모델에 포함할 수 있습니다.
- 데이터 수집 과정에서 발생한 누락을 보완하여 모델의 일반화 성능을 높입니다.

2. 스케일링

방법론: StandardScaler (표준화)

상세 설명:

- 각 특성을 평균 0, 표준편차 1이 되도록 표준화합니다.
- 서로 다른 단위를 가진 특성들이 동등한 비중으로 모델에 반영되도록 합니다.
- 거리 기반 알고리즘(SVM, KNN 등)과 경사 하강법 기반 모델의 성능을 향상시킵니다.

비즈니스 의미:

- 시간(분), 금액(원), 사용량(회) 등 서로 다른 단위의 데이터를 비교 가능한 형태로 변환합니다.
- 특성 간의 상대적 중요도를 올바르게 파악할 수 있어 모델 해석에 도움이 됩니다.

3. 특성 선택

방법론: SelectKBest (f_classif)

상세 설명:

- F-검정(F-test)을 통해 다것 변수와의 상관관계가 높은 상위 K개 특성을 선택합니다.
- 불필요한 특성을 제거하여 차원의 저주를 방지하고 모델 학습 속도를 향상시킵니다.
- 과적합 위험을 줄이고 모델의 해석 가능성을 높입니다.

비즈니스 의미:

- 이탈 예측에 실제로 중요한 요인만을 식별하여 비즈니스 인사이트를 도출합니다.
- 데이터 수집 비용을 절감하고 모델 유지보수를 용이하게 합니다.
- 핵심 리텐션 요인을 파악하여 마케팅 전략 수립에 활용될 수 있습니다.

4. 데이터 분할

방법론: Train/Validation/Test (60%/20%/20%)

상세 설명:


- Train (60%):** 모델 학습에 사용되는 데이터로 모델 패턴 학습
- Validation (20%):** 하이퍼파라미터 튜닝 및 모델 선택에 사용
- Test (20%):** 최종 모델 성능 평가에 사용 (학습 과정에서 미사용)

비즈니스 의미:

- 과적합 방지를 통해 실제 환경에서의 모델 성능을 보장합니다.
- 다양한 데이터 분포에서 모델의 안정성을 검증합니다.
- 신뢰할 수 있는 성능 지표를 통해 비즈니스 의사결정을 지원합니다.

데이터 분할 비율

데이터 분할



선택된 특성 분석

총 30개 특성이 선택되었습니다.

특성 카테고리별 분포



특성 카테고리별 상세 정보

📅 시간 관련 특성

개수: 21개

설명: 사용자의 OTT 서비스 이용 시간 패턴을 나타내는 특성

주요 특성:

- ott_time_mean
- ott_time_std
- ott_time_cv
- ott_time_trend
- ott_time_max
- 등 총 21개

📊 사용량 01 관련 특성

개수: 6개

설명: 사용자의 OTT 서비스 사용량 데이터 (첫 번째 기간)

주요 특성:

- ott_usage_01_mean
- ott_usage_01_trend
- ott_usage_01_change_last
- ott_usage_01_recent_mean
- ott_usage_01_usage_years_count
- 등 총 6개

>>Deploy

2	사용자별 집계	각 사용자별로 시계열 데이터를 집계 (User-level Aggregation)	사
3	이탈 정의 적용	최근 3개월 사용량이 전체 평균의 50% 미만일 경우 이탈로 정의 (Time-based Churn Def	이
4	피처 엔지니어링	시계열 통계량 추출 (mean, std, cv, trend, max, min 등 48개 피처)	48
5	전처리 완료	데이터 누수 방지 특성 제거 및 최종 데이터셋 생성	11

원본 데이터셋

파일	설명	주요 컬럼	데이터 형태
data/ott_money.csv	OTT 금액 데이터	pid YEAR ott_money	시계열 (사용자별 연도별)
data/ott_time.csv	OTT 시간 데이터	pid YEAR ott_time	시계열 (사용자별 연도별)
data/ott_usage_01.csv	OTT 사용량 데이터 (Type 01)	pid YEAR ott_usage_01	시계열 (사용자별 연도별)
data/ott_usage_02.csv	OTT 사용량 데이터 (Type 02)	pid YEAR ott_usage_02	시계열 (사용자별 연도별)

피처 생성 구조

📁 기본 피처 (4개)

피처명	설명	데이터 형태
ott_money	OTT 금액	시계열 (사용자별 연도별)
ott_time	OTT 시간	시계열 (사용자별 연도별)
ott_usage_01	OTT 사용량 (Type 01)	시계열 (사용자별 연도별)
ott_usage_02	OTT 사용량 (Type 02)	시계열 (사용자별 연도별)

NEW 생성된 피처 (48개) - 피처 엔지니어링

기본 4개 피처에서 시계열 통계량을 추출하여 48개 피처 생성

카테고리	기본 피처	생성 피처 수	주요 통계량
시간 관련	ott_time	23개	mean, std, cv, trend, max, min, change_last, decline_count, max_drop, rece
사용량 01	ott_usage_01	13개	mean, std, cv, trend, change_last, decline_count, max_drop, recent_mean,
사용량 02	ott_usage_02	12개	mean, std, cv, trend, change_last, decline_count, max_drop, recent_mean,

🔑 피처 엔지니어링 상세 설명

> 피처 엔지니어링 통계량 설명

전처리 결과 요약

원본 사용자	전처리 후	손실 사용자	손실률
11,040	11,040	0	0.0%

데이터 손실 과정



데이터 손실 원인

	단계	설명	예상 손실
0	결측치 제거	결측치가 너무 많은 사용자 제거	약 5%
1	사용자별 집계	데이터가 부족한 사용자 제거	약 3%
2	이탈 정의 적용	이탈 정의에 맞지 않는 사용자 제거	약 2%

데이터 분석

1. 데이터 기본 정보

총 샘플 수	총 피쳐 수	수치형 피쳐	범주형 피쳐
11,040	52	51	1

2. 데이터셋 파일 정보

기본 제공 데이터셋

- data/ott_money.csv
- data/ott_time.csv
- data/ott_usage_01.csv
- data/ott_usage_02.csv

NEW 생성된 데이터셋

- data/ott_data_v.0/
- data/ott_data_v.2/

3. 피쳐 분류 정보

기본 제공 피쳐

총 4개

- ott_money
- ott_time
- ott_usage_01
- ott_usage_02

NEW 생성된 피쳐 (엔지니어링)

총 49개

카테고리	개수
시간 관련	23
사용량 01	13
사용량 02	12

생성된 피쳐 상세 목록

시간 관련 피쳐

피쳐명
ott_time_mean
ott_time_std
ott_time_cv
ott_time_trend
ott_time_max
ott_time_min
ott_time_change_last
ott_time_decline_count
ott_time_max_drop
ott_time_recent_mean

사용량 01 피쳐

피쳐명
ott_usage_01_mean
ott_usage_01_std
ott_usage_01_cv
ott_usage_01_trend
ott_usage_01_change_last
ott_usage_01_decline_count
ott_usage_01_max_drop
ott_usage_01_recent_mean
ott_usage_01_usage_years_count
ott_usage_01_consecutive_decline_count

사용량 02 피쳐

피쳐명
ott_usage_02_mean
ott_usage_02_std
ott_usage_02_cv
ott_usage_02_trend
ott_usage_02_change_last
ott_usage_02_decline_count
ott_usage_02_max_drop
ott_usage_02_recent_mean
ott_usage_02_usage_years_count
ott_usage_02_consecutive_decline_count

4. 결측치 분석

결측치가 있는 피쳐: 7개

	Feature	Missing Count	Missing %
1	ott_money	9631	87.2373
39	ott_usage_02_std	1746	15.8152
40	ott_usage_02_cv	1746	15.8152
4	ott_time_cv	853	7.7264
3	ott_time_std	853	7.7264
27	ott_usage_01_cv	566	5.1268
26	ott_usage_01_std	566	5.1268

상위 20개 피쳐 결측치 비율



1. 모델 성능 비교

설명: 각 모델의 성능 지표(Accuracy, Precision, Recall, F1-Score, ROC-AUC)를 비교합니다. 모델별로 어떤 지표에서 우수한 성능을 보이는지 확인할 수 있습니다.

모델 성능 비교

모델 성능 테이블

Task	Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
OTT	XGBoost_Tuned	0.9864	0.9114	0.96	0.9351	0.9974
OTT	LightGBM_Tuned	0.9882	0.927	0.96	0.9432	0.9979
OTT	CatBoost_Tuned	0.9823	0.8875	0.9467	0.9161	0.997
OTT	Ensemble	0.9864	0.9079	0.9644	0.9353	0.9976
OTT	Stacking	0.9841	0.8992	0.9511	0.9244	0.9974
OTT	DeepLearning_Transfer	0.9769	0.8271	0.9778	0.8961	0.9971


모델별 성능 비교

OTT

성능 지표 선택

Accuracy

OTT - Accuracy 비교



최고 성능 모델

Task	Best Model	F1-Score
OTT	LightGBM_Tuned	0.9432

2. Confusion Matrix

설명: 모델의 예측 결과를 실제 값과 비교한 혼동 행렬입니다.

- True Positive (TP): 실제 이тал을 이탈으로 올바르게 예측
- True Negative (TN): 실제 비이탈을 비이탈으로 올바르게 예측
- False Positive (FP): 실제 비이탈을 이탈으로 잘못 예측 (Type I Error)
- False Negative (FN): 실제 이탈을 비이탈로 잘못 예측 (Type II Error)

Confusion Matrix

모델 선택

OTT_XGBoost_Tuned_val

OTT_XGBoost_Tuned_val - Confusion Matrix



Accuracy	Precision	Recall	F1-Score
0.9819	0.9039	0.9200	0.9119

3. ROC Curve

설명: Receiver Operating Characteristic 곡선으로, 다양한 임계값에서의 모델 성능을 보여줍니다.

- X축: False Positive Rate (1 - Specificity)
- Y축: True Positive Rate (Recall/Sensitivity)
- AUC (Area Under Curve): 곡선 아래 면적, 1에 가까울수록 좋은 모델
- 대각선: 랜덤 분류기 기준선

ROC Curve


모델 선택 (여러 개 선택 가능)

OTT_XGBoost_Tuned x

OTT_LightGBM_Tu... x



ROC Curve Comparison



4. Precision-Recall Curve

설명: 정밀도(Precision)와 재현율(Recall)의 관계를 보여주는 곡선입니다.

- 불균형 데이터셋에서 ROC 곡선보다 유용할 수 있습니다.
- AP (Average Precision): 곡선 아래 면적, 1에 가까울수록 좋은 모델
- Precision-Recall 트레이드오프를 확인할 수 있습니다.

Precision-Recall Curve


모델 선택 (여러 개 선택 가능)

OTT_XGBoost_Tuned x

OTT_LightGBM_Tu... x



Precision-Recall Curve Comparison



8. Threshold-F1 Curve

설명: 다양한 임계값(Threshold)에 따른 F1 점수 변화를 보여줍니다.

- 임계값이 낮으면 재현율(Recall)이 높아지고 정밀도(Precision)가 낮아짐
- 임계값이 높으면 정밀도(Precision)가 높아지고 재현율(Recall)이 낮아짐
- 최적 임계값: F1 점수가 가장 높은 지점
- 비즈니스 목표에 따라 임계값을 조정할 수 있습니다.




Threshold-F1 Curve

모델 선택

OTT_XGBoost_Tuned

OTT_XGBoost_Tuned - Threshold vs F1 Score



최적 임계값

0.5000

최적 F1 Score

0.0000

9. Top10 High Risk Customers ↔

설명: 이탈 확률이 가장 높은 상위 10명의 고객을 보여줍니다.

- 리텐션 마케팅의 우선순위를 결정하는 데 활용할 수 있습니다.
- 고위험 고객에게 타겟팅 캠페인을 실행하여 이탈을 방지할 수 있습니다.
- Precision@10 지표와 연관됩니다.



Top10 High Risk Customers

순위	고객 ID	이탈 확률	평균 시청 시간	평균 사용량 01	평균 사용량 02
1	7550004	1	2.6667	10	6.75
2	53620001	0.9999	2.6667	10	0
3	114560003	0.9999	2.3333	10	10.3333
4	3160002	0.9999	3	10	0
5	17500002	0.9999	3	10	0
6	27000002	0.9999	2.6667	8.6667	10
7	69690001	0.9999	1.8	9	8.6667
8	28850102	0.9999	3	9	9
9	65540001	0.9999	3.6667	10	8
10	6960002	0.9999	3	10	8

Top10 고객 이탈 확률

